SKN-26기_3M

Churn Prediction

통신사 가입 고객 이탈 예측

SKN-26 3M

INDEX

목차

1 RoadMap

2 개요

3 EDA

4 Preprocessing

5 Modeling

6 Trouble Shooting

7 개선 방향

8 결론

1 RoadMap

1

STEP 01

주제 탐색

2

STEP 02

주제 확정 및 데이터 수집

3

STEP 03

코드 설계

4

STEP 04

코드 보완 및 고도화

5

STEP 05

인사이트 공유 및 발표 준비

Overview

개요

기획 의도

누가 떠날지 알면
떠나기 전에 잡을 수 있다.

목표

개인 조사 데이터를 활용하여
통신사 이탈 가능성을 예측하는
모델 분석 및 비교

Overview

개요

기대 효과

데이터 기반 예측 모델로
통신사 고객 유지율 향상
알뜰폰 전환 방어에 기여

구조 요약

데이터	KMP 2020_2025.csv (41, 299행)
입력 변수	7개 핵심 특성
비교 모델	5개 (LR / DT / RF / GB / XGB)
검증 방법	pid 기반 GroupFold (5-fold)
핵심 지표	F1, Recall, PR-AUC

3 EDA

Feature Columns

pid	동일 개인 식별자
year_t0	이전 시점 연도
year_t1	다음 시점 연도
telco_t0	이전 시점 통신사
telco_t1	다음 시점 통신사
a03002_tminus1	스마트폰/5G 관련
a03024_tminus1	음성 무제한 여부
a03026_tminus1	데이터 무제한 여부
c01002_tminus1	월평균 휴대폰 이용금액
c01004_tminus1	통신 지출/가계 관련
c02003_tminus1	특정 서비스 이용 여부
c02001_tminus1	이용 행태 관련

Label Columns

churn_any	전체 통신사 변경 여부
churn_to_mvno	메이저 → 알뜰폰 이동 여부

3 EDA

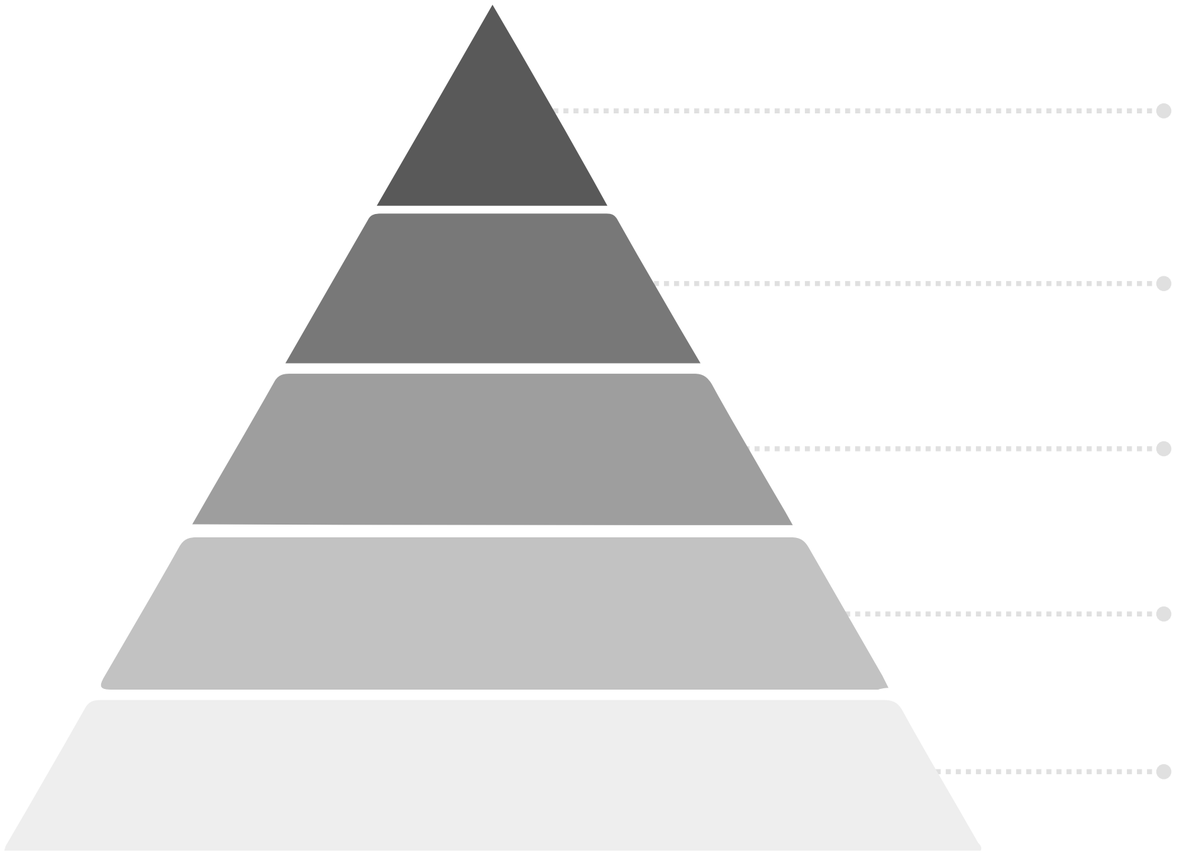

3 EDA

데이터 기본 구조 확인

```
기본 정보
<class 'pandas.DataFrame'>
RangeIndex: 41299 entries, 0 to 41298
Data columns (total 17 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   pid              41299 non-null  int64
 1   year_t0          41299 non-null  int64
 2   year_t1          41299 non-null  int64
 3   telco_t0         41299 non-null  float64
 4   telco_t1         41299 non-null  float64
 5   churn_any        41299 non-null  int64
 6   churn_to_mvno    41299 non-null  int64
 7   a03002_tminus1   41299 non-null  float64
 8   a03024_tminus1   41299 non-null  float64
 9   a03026_tminus1   41299 non-null  float64
 10  c01002_tminus1   41299 non-null  float64
 11  c01004_tminus1   41299 non-null  float64
 12  c02003_tminus1   41299 non-null  float64
 13  c02001_tminus1   41299 non-null  float64
 14  age1_tminus1     41299 non-null  int64
 15  income1_tminus1  41299 non-null  int64
 16  job1_tminus1     41299 non-null  int64
dtypes: float64(9), int64(8)
memory usage: 5.4 MB
None
```

연도 전환 구조 확인

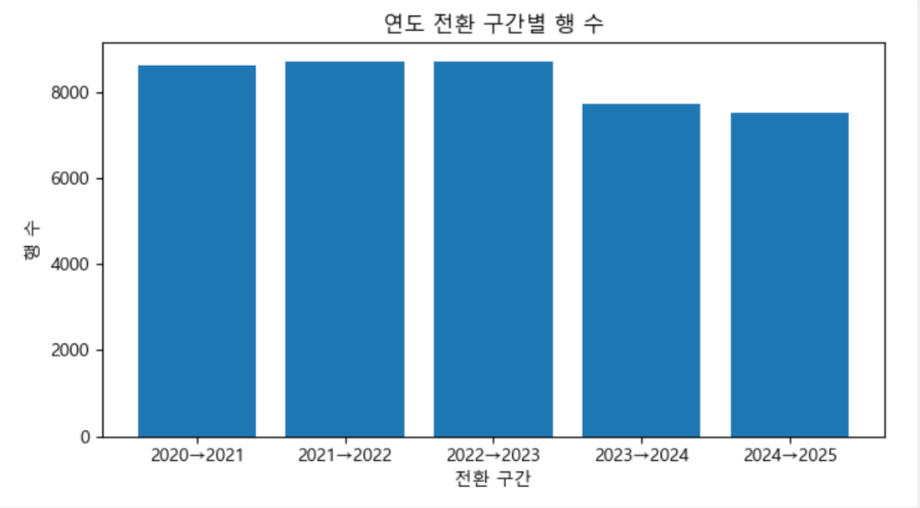

3 EDA

라벨 분포 확인 - churn_any

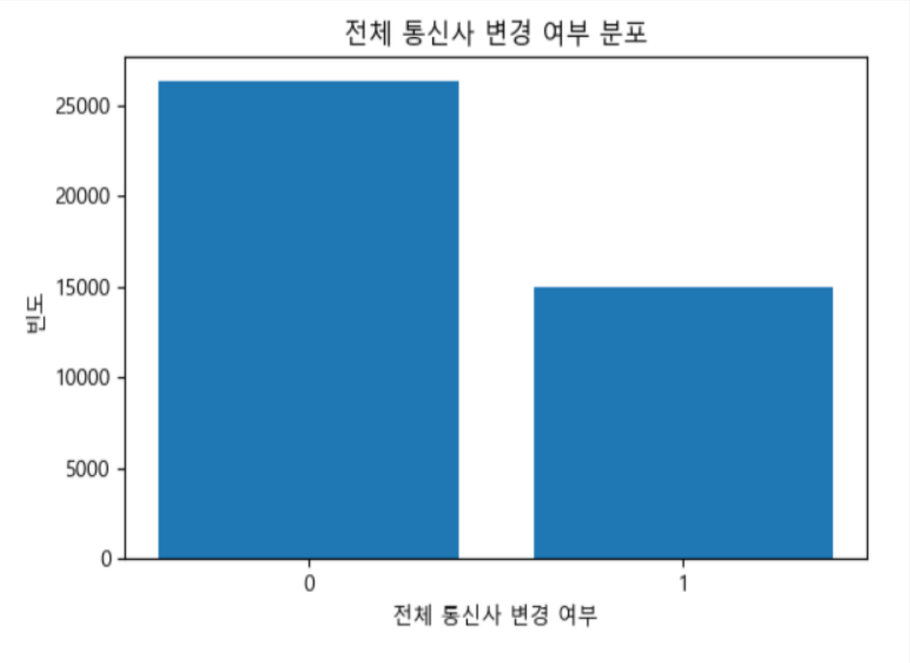

라벨 분포 확인 - churn_to_move

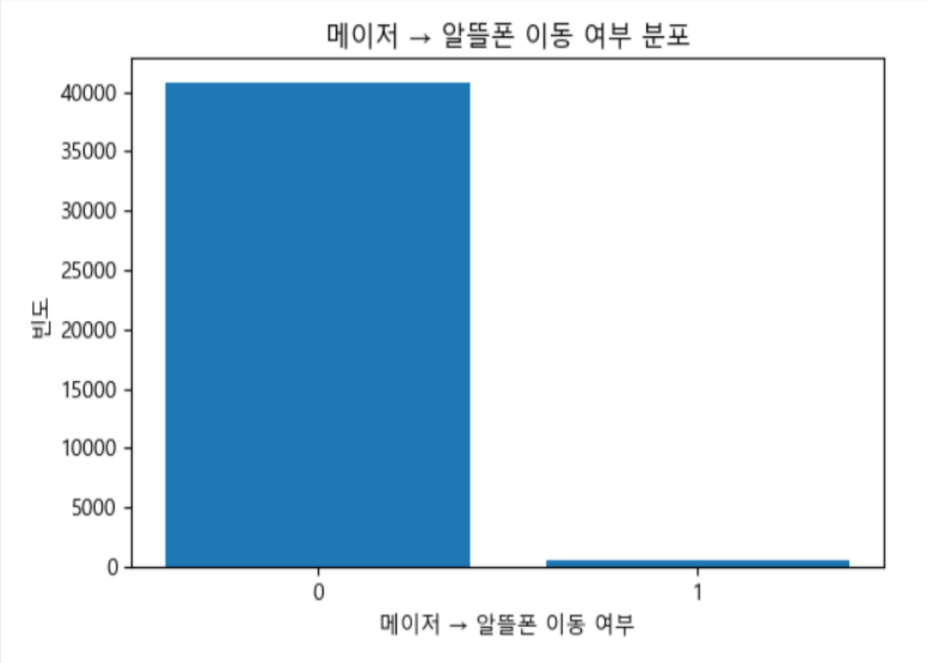

3 EDA

핵심 변수 분포 확인

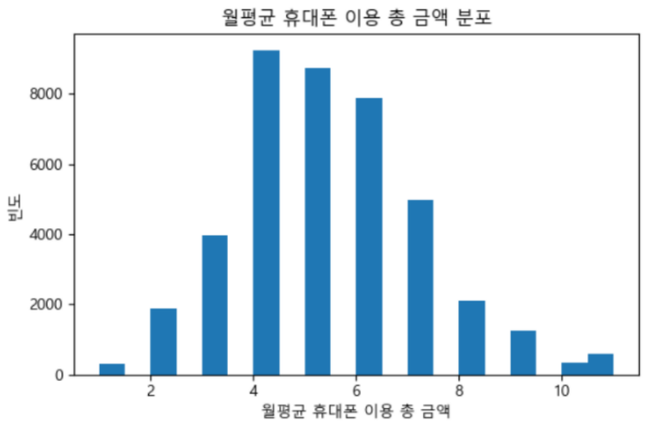

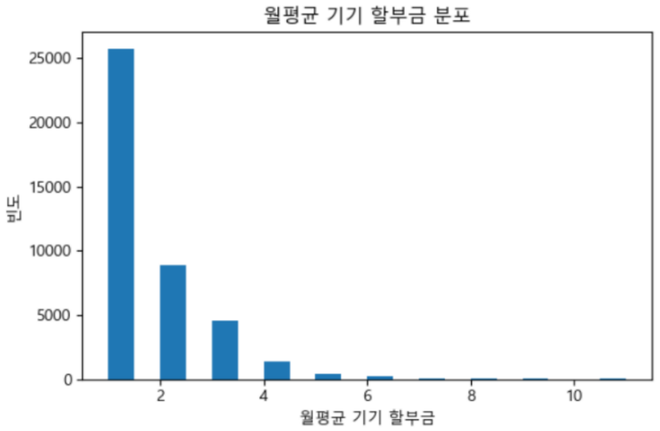

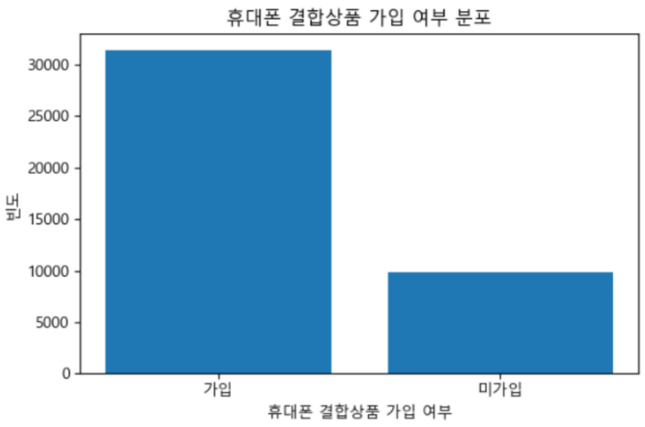

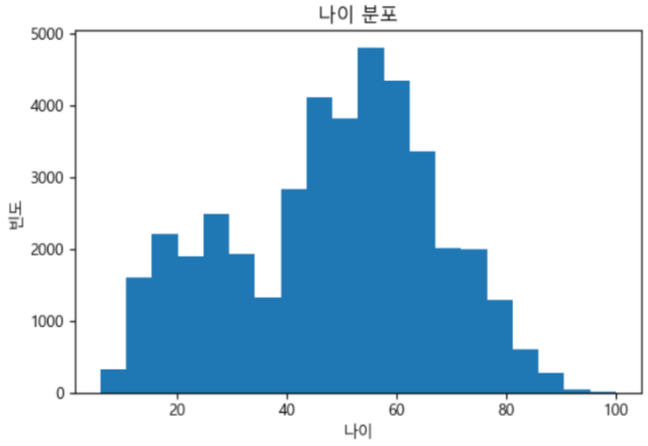

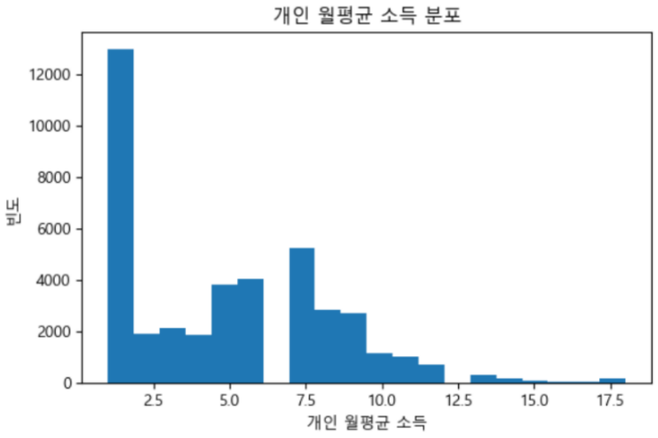

변수 간 상관관계 확인

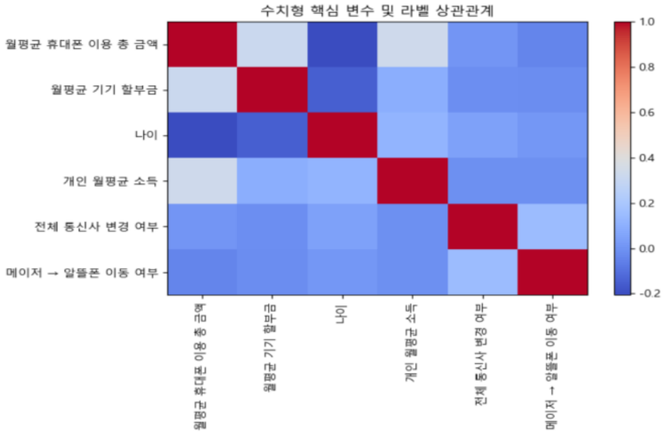

4 Preprocessing

결측 코드 처리	9997, 9998, 9999를 NaN으로 변환
이진변수 1/2 → 1/0	일부 이진 변수는 모델 입력에 맞게 1/0으로 정리
공백 / NBSP 제거	문자형 컬럼의 불필요한 공백 제거
중복 제거	pid, year_t0, year_t1 기준 중복 제거
통신사 유효값 유지	통신사 코드 1, 2, 3, 4만 유지
누수 방지	예측에는 t-0, t-1 변수만 사용 telco 관련 컬럼 제외

4 Preprocessing

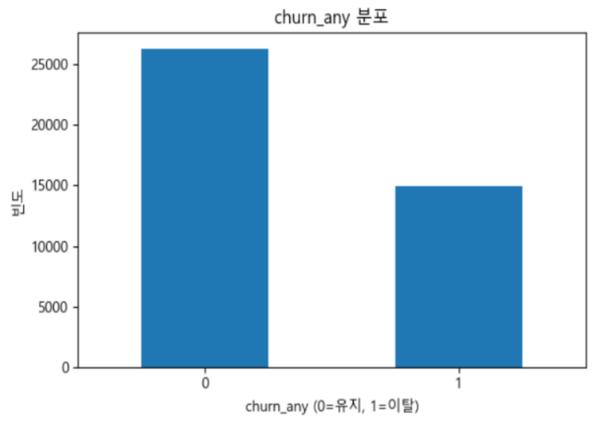

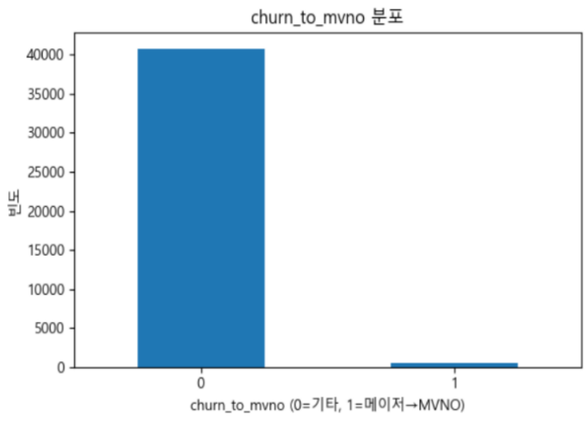

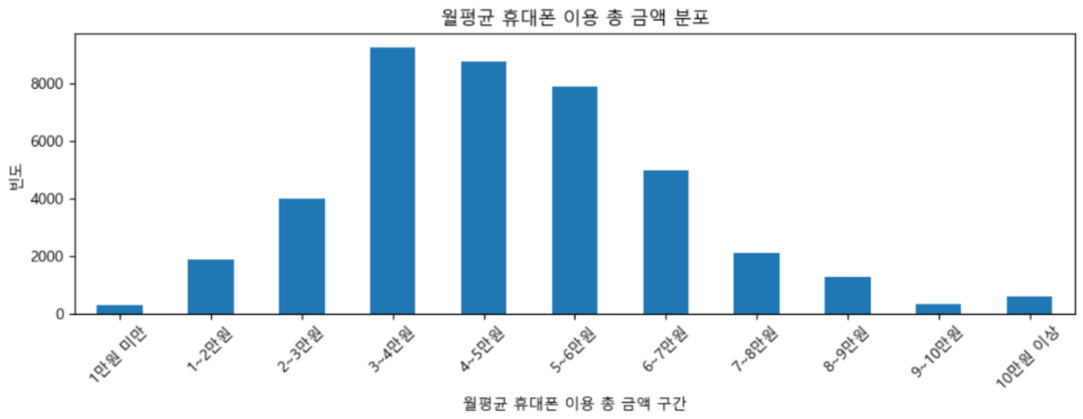

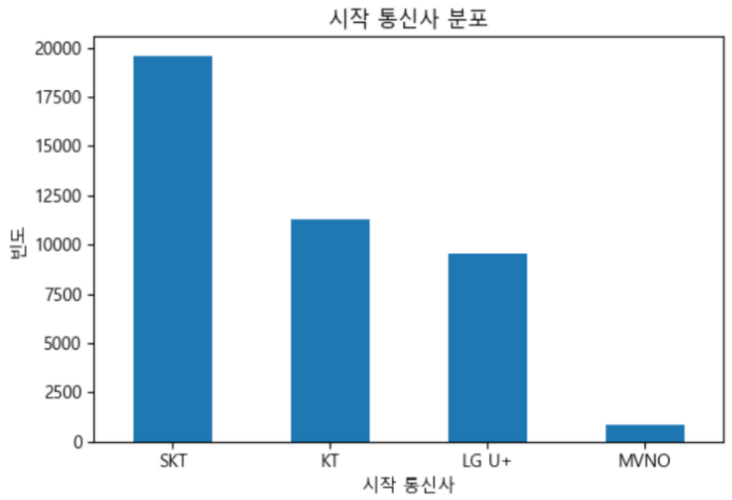

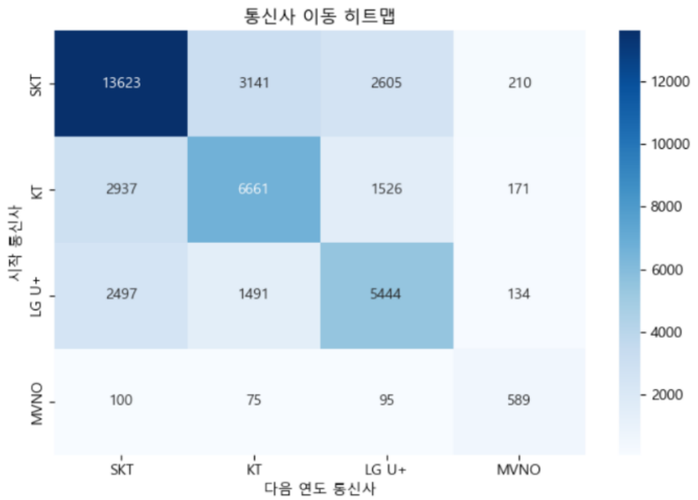

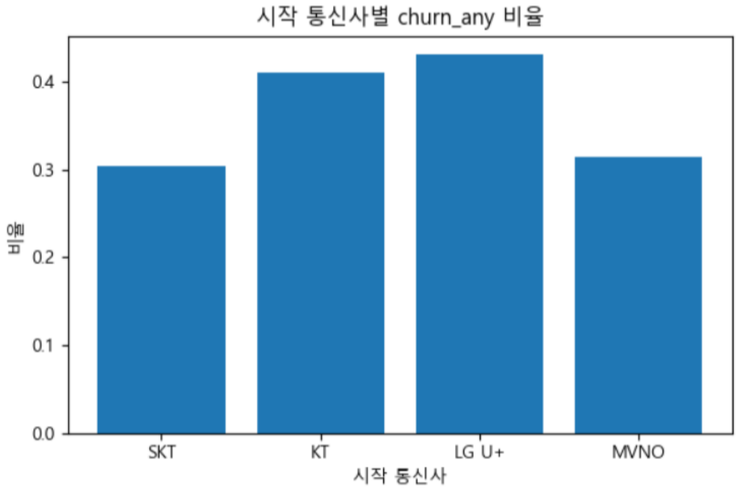

5 Modeling

model	accuracy	precision	recall	f1	roc_auc	pr_auc
XGBoost	0.645600	0.458647	0.020798	0.039791	0.591229	0.418562
GradientBoosting	0.645119	0.397260	0.009887	0.019295	0.589186	0.414832
RandomForest	0.573853	0.411231	0.479373	0.442695	0.576183	0.409014
LogisticRegression	0.524257	0.381429	0.558814	0.453389	0.547991	0.383012
DecisionTree	0.450825	0.378451	0.864644	0.526469	0.552298	0.380511

6 Trouble Shooting

churn_to_mvno : 3대 통신사 → 알뜰폰

model	accuracy	precision	recall	f1	roc_auc	pr_auc
LogisticRegression	0.611051	0.014202	0.547619	0.027686	0.614490	0.018908
DecisionTree	0.618394	0.014169	0.535714	0.027607	0.592262	0.013365
RandomForest	0.975322	0.016000	0.023810	0.019139	0.615446	0.014433
GradientBoosting	0.989768	0.000000	0.000000	0.000000	0.643558	0.025239
XGBoost	0.989888	0.000000	0.000000	0.000000	0.638272	0.020732

6 Trouble Shooting

RandomForest 특성 중요도 확인

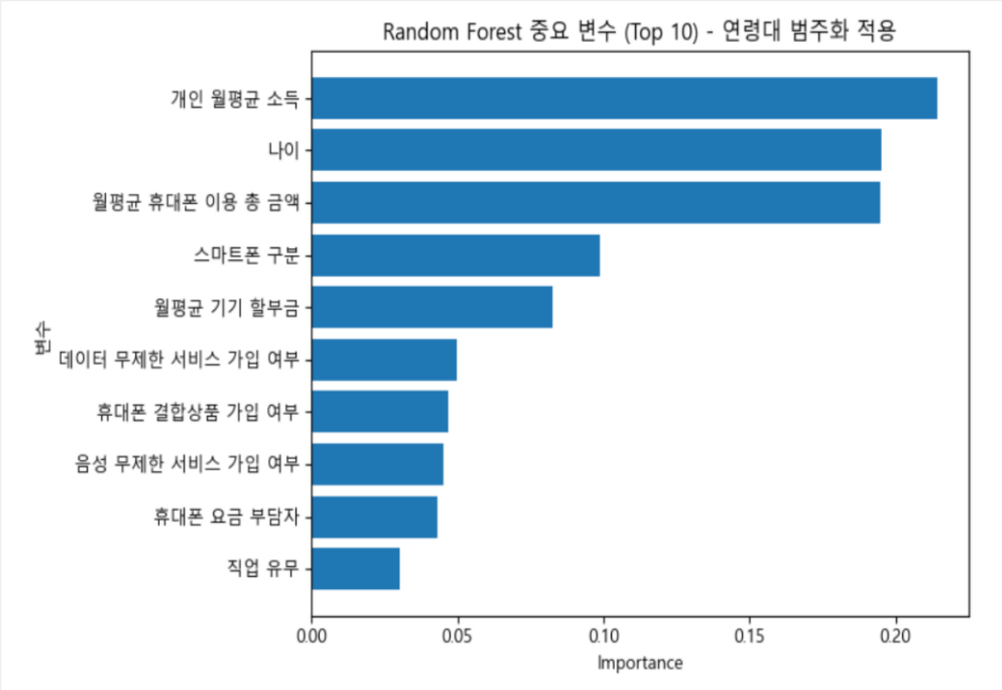

XGBoost - 특성 중요도 확인

변수	중요도
월평균 휴대폰 이용 총 금액	0.111537
개인 월평균 소득	0.105549
휴대폰 요금 부담자	0.104962
데이터 무제한 서비스 가입	0.103447
나이	0.100299
직업 유무	0.098642
음성 무제한 서비스 가입 여	0.098248
휴대폰 결합상품 가입 여부	0.095930
스마트폰 구분	0.091107
월평균 기기 할부금	0.090279

6 Trouble Shooting

LogisticRegression - Precision Recall Curve

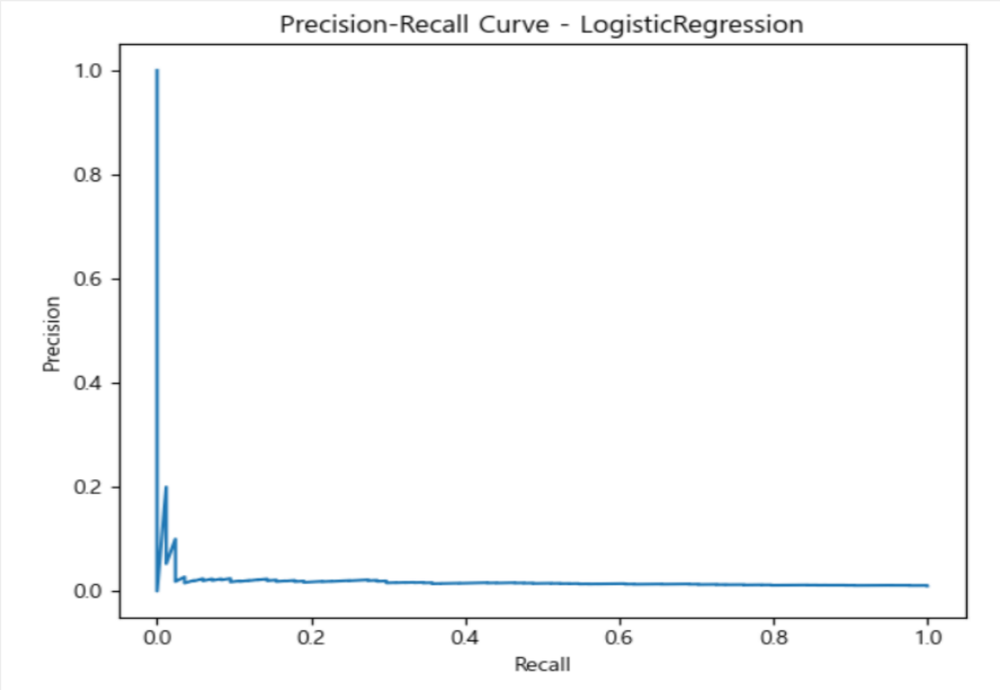

LogisticRegression - Threshold별 성능 변화

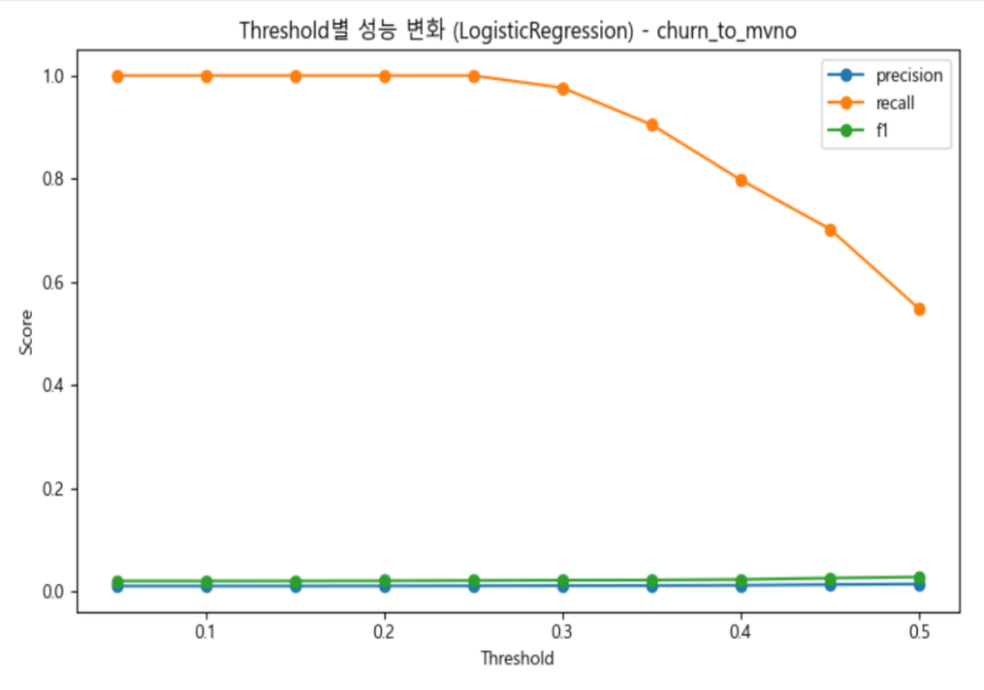

6 Trouble Shooting

```
최적의 임계값 (Optimal Threshold): 0.6111
최고 F1 스코어 (Max F1 Score): 0.0402

[ 최적 임계값 적용 후 분류 리포트 ]
              precision    recall  f1-score   support

           0       0.99      0.87      0.93      8223
           1       0.02      0.27      0.04        84

    accuracy                           0.87      8307
   macro avg       0.51      0.57      0.48      8307
weighted avg       0.98      0.87      0.92      8307
```

6 Trouble Shooting

핵심 한계점

극단적 클래스 불균형

전체의 1%인 84명이 실제 이탈자

모델이 배울 수 있는 단서가 절대적으로
부족해 강력한 알고리즘도 이탈자를
아예 못 잡는 현상 발생

변수 변별력 한계 & 높은 오탐률

이탈자를 더 잡을수록 오탐지 폭증

나이·소득·요금 등 10개 변수만으로는
이탈자와 비이탈자를 구분하기 어려워,
Precision 1~2%대

단일 시점 기반 예측 한계

**작년 데이터로 올해 이탈을
예측하는 구조**

요금 증가 추세나 사용량 급감 같은
변화 흐름을 반영하지 못해
정확한 이탈 타이밍의 예측 어려움

7 개선 방향

잠재 고위험군 식별

모델이 찾아낸 98%의 고객은 실제로 떠난 사람들과
같은 요금 불만을 가지고 있는 잠재적 이탈 위험군

이탈의 과정 이해

98%의 잔류 인원은 서비스 만족이 아닌
물리적 족쇄로 인한 지연 상태

모델 역할 재정의

1% 예측의 한계를 인정,
모델을 조기 경보 레이더로 재정의하여 통신비 불만을
가진 98% 위기 고객을 선제적으로 선별

데이터 기반 리텐션

모델이 포착한 타겟에게
맞춤형 요금제 컨설팅이나 기기변경 혜택을 집중

7 결론

Thank You

감사합니다

여백을 충분히 두어 시선이 오직 텍스트에만 집중되도록 하세요.

"백 마디 말보다 잘 고른 한 장의 문장이 더 강력한 메시지를 전달한다."